

MODELO DE RISCO DE DESLIGAMENTO

Probabilidade de dispensa sem justa causa

Ensemble CatBoost · dados públicos RAIS · 82,96 milhões de vínculos (2023)

AUC

0,741

holdout 2023

LogLoss

0,348

bem calibrado

Categorias

23

ganho de informação

Personas

5 grupos

do servidor à obra

Conteúdo: 1) Desenvolvimento e treino do modelo 2) Categorização do risco 3) Personas por grupo de risco

O problema e a abordagem

Objetivo

- ▶ Estimar a probabilidade de um vínculo formal ser encerrado por
- ▶ dispensa sem justa causa nos meses seguintes.

Dados

- ▶ RAIS (Relação Anual de Informações Sociais) — base pública nacional
- ▶ de todos os vínculos formais. Anos 2019–2023, ~280 milhões de vínculos.

Validação honesta (out-of-time)

- ▶ Treina em ≤ 2022 e testa em 2023, ano nunca visto — mede a capacidade
- ▶ real de prever o futuro, não de decorar o passado.

Em números

Vínculos no teste (2023)	82,96 mi
Taxa real de dispensa	13,3%
Features do modelo	22
AUC (holdout)	0,741
Erro de calibração	< 1 p.p.
Categorias de risco	23

Preparação: features e harmonização de códigos

22 features por vínculo (todas disponíveis na RAIS)

- ▶ Ocupação (CBO) e setor (CNAE) — em níveis hierárquicos (6→1 dígito)
- ▶ Tempo de vínculo, idade, tipo de contrato, faixa de remuneração,
- ▶ tamanho e natureza da empresa, jornada, afastamentos, UF.


Harmonização de códigos entre anos (pré-processamento)

- ▶ Alguns códigos mudaram de formato entre 2022 e 2023; sem
- ▶ padronizar, o modelo veria categorias 'novas' (desconhecidas)
- ▶ no teste de 2023. A normalização garante consistência.

campo	≤ 2022	em 2023	→ normalizado
faixa salarial	02	2	2
afastamento	99	999	99
CBO (militar)	010105	10105	010105

Ex.: a categoria majoritária de afastamento ('99', ~84% dos vínculos) virava '999' em 2023 — vista como desconhecida sem o ajuste.

Como o ensemble base foi treinado



Por que cross-temporal?

- ▶ Cada modelo aprende de um par de anos
- ▶ e valida no outro; a média reduz variância.


Algoritmo

- ▶ CatBoost (gradient boosting) em GPU
- ▶ Perda e early-stopping em LogLoss
- ▶ Trata categóricas nativamente


Resultado (holdout 2023)

- ▶ AUC 0,741 · LogLoss 0,348

Desempenho: discrimina bem e é bem calibrado



Calibração: risco previsto $\approx$ observado em todos os decis (erro < 1 p.p.).
Risco de Desligamento · RAIS 2019-2023 · holdout 2023



Importância: tempo de vínculo, tipo de contrato e faixa salarial dominam (~45%).

Categorização do risco

Do score contínuo a faixas interpretáveis — maximizando o ganho de informação

Cortes que maximizam o ganho de informação

Ideia


- ▶ Fatiar a probabilidade prevista em faixas que separem ao máximo quem é desligado de quem não é (ganho de informação sobre o alvo).

Como

- ▶ Para cada nº de categorias K , a divisão ótima é achada por
- ▶ programação dinâmica (maximiza a informação mútua $I(\text{faixa}; \text{alvo})$).


Critério de parada

- ▶ Aumenta-se K enquanto o risco médio das faixas continua
- ▶ estritamente crescente. Quando a ordem quebra, para.



As 23 categorias de risco (ponto ótimo)

cat	faixa de prob.	n (mi)	taxa real	prob. méd.	lift
1	0.000-0.005	5.5	0.6%	0.2%	0.05×
2	0.005-0.007	1.0	1.4%	0.6%	0.11×
3	0.007-0.038	7.0	2.9%	2.3%	0.22×
4	0.038-0.050	3.7	4.1%	4.4%	0.31×
5	0.050-0.063	4.3	5.4%	5.7%	0.40×
6	0.063-0.077	5.1	6.6%	7.0%	0.50×
7	0.077-0.095	6.8	8.1%	8.6%	0.61×
8	0.095-0.111	6.1	9.5%	10.3%	0.72×
9	0.111-0.126	5.5	11.0%	11.9%	0.83×
10	0.126-0.144	6.1	12.7%	13.5%	0.95×
11	0.144-0.161	5.2	14.5%	15.2%	1.09×
12	0.161-0.178	4.6	16.3%	16.9%	1.23×
13	0.178-0.195	4.0	18.3%	18.6%	1.38×
14	0.195-0.213	3.4	20.4%	20.4%	1.53×
15	0.213-0.240	3.7	22.9%	22.6%	1.72×
16	0.240-0.276	3.2	26.0%	25.6%	1.96×
17	0.276-0.310	1.8	29.1%	29.2%	2.19×
18	0.310-0.376	2.2	31.9%	34.0%	2.40×
19	0.376-0.437	1.2	35.4%	40.4%	2.66×
20	0.437-0.525	1.0	39.9%	47.6%	3.00×
21	0.525-0.672	0.9	46.1%	59.1%	3.47×
22	0.672-0.732	0.2	57.1%	70.1%	4.30×
23	0.732-0.973	0.5	66.7%	80.8%	5.02×



Personas das categorias


Quem é cada grupo de risco — segundo as variáveis da RAIS

Como cada categoria foi perfilada

Duas medidas por característica

- ▶ Composição interna: do que a categoria é feita (% de cada valor).
- ▶ Distintividade (lift): $\text{share na categoria} \div \text{share na base}$ —
- ▶ o que é desproporcionalmente comum ali (piso de 5%).

O gradiente: do setor público (estável) à construção civil (alta rotatividade)




O servidor público concursado

Categorias 1-2 · risco 0.6%-1.4% · 6.5 mi de vínculos (8% da base)

- ▶ Servidores estatutários da administração pública e educação; militares fortemente sobre-representados (lift 10×).
- ▶ Meia-idade (~46 anos), longuíssimo tempo de casa (~15 anos), nível superior, grandes órgãos.
- ▶ Estabilidade legal do serviço público → risco quase nulo (0,6–1,4%).

Perfil do grupo (médias ponderadas)



0.8%

Risco médio do grupo

46 anos

Idade média

15.7 anos

Tempo de vínculo

6%


Ensino fundamental

CLT consolidado na indústria e na saúde

Categorias 3-6 · risco 3.0%-6.6% · 20.2 mi de vínculos (24% da base)

- ▶ CLT por prazo indeterminado em indústria de alimentos e atividades de saúde; empresas de porte médio/grande.
- ▶ 5-6 anos de casa, ensino médio/superior, ~37 anos.
- ▶ Vínculo estável e maduro fora do setor público (risco 3-6,6%).

Perfil do grupo (médias ponderadas)



4.6%

Risco médio do grupo

37 anos

Idade média

6.2 anos

Tempo de vínculo

8%


Ensino fundamental

CLT do comércio e dos serviços de apoio

Categorias 7-11 · risco 8.1%-14.5% · 29.6 mi de vínculos (36% da base)

- ▶ Comércio varejista/atacadista e serviços terceirizados (limpeza, escritório, apoio a empresas).
- ▶ Empresas pequenas, muitas optantes do Simples; 2-4 anos de casa, trabalhadores mais jovens.
- ▶ Maior rotatividade típica do comércio e serviços (risco 8-14,5%).

Perfil do grupo (médias ponderadas)



11.0%

Risco médio do grupo

36 anos

Idade média

2.8 anos

Tempo de vínculo

7%


Ensino fundamental

Alimentação, varejo e o início da construção

Categorias 12-17 · risco 16.4%-29.1% · 20.7 mi de vínculos (25% da base)

- ▶ Bares, restaurantes e varejo; a partir daqui entram a produção industrial e a construção civil.
- ▶ Vínculos curtíssimos (~1,5-2 anos), micro/pequenas empresas, escolaridade começando a cair.
- ▶ Setores de alta rotatividade estrutural (risco 16-29%).

Perfil do grupo (médias ponderadas)



21.2%

Risco médio do grupo

36 anos

Idade média

1.7 anos

Tempo de vínculo

8%


Ensino fundamental

Operário da construção civil em micro construtora

Categorias 18-23 · risco 31.9%-66.7% · 6.0 mi de vínculos (7% da base)

- ▶ Construção de edifícios e obras de infraestrutura — fortíssima sobre-representação (CNAE 41/42, lift até 7,6×).
- ▶ Micro/pequenas construtoras, ensino fundamental, remuneração baixa; majoritariamente CLT 'indeterminado'.
- ▶ O modelo capta a rotatividade ESTRUTURAL do setor: na cat 23, 2 em cada 3 são desligados no ano (66,7%).

Perfil do grupo (médias ponderadas)



40.0%

Risco médio do grupo

37 anos

Idade média

1.9 anos

Tempo de vínculo

12%

Ensino fundamental

Síntese

- Ensemble CatBoost cross-temporal prevê dispensa sem justa causa com AUC 0,741 e boa calibração.
- A harmonização de códigos entre anos garante a consistência do modelo no teste de 2023.
- O score foi fatiado em 23 categorias ótimas (máximo ganho de informação mantendo a ordenação).
- As personas vão do servidor público estável (risco ~1%) ao operário da construção em micro construtora (risco ~67%) — o modelo capta rotatividade estrutural, não só contrato temporário.

△ Uso ético/LGPD: análise agregada e descritiva; decisões sobre indivíduos exigem revisão humana e cuidado com vieses (setor, escolaridade, região).