

MODELO DE RISCO DE DESLIGAMENTO

Probabilidade de dispensa sem justa causa

Ensemble CatBoost · dados públicos RAIS · 82,96 milhões de vínculos (2023)

AUC

0,741

holdout 2023

LogLoss

0,348

bem calibrado

Categorias

23

ganho de informação

Personas

5 grupos

do servidor à obra

Conteúdo: 1) Desenvolvimento e treino do modelo 2) Categorização do risco 3) Personas por grupo de risco

O problema e a abordagem

Objetivo

- ▶ Estimar a probabilidade de um vínculo formal ser encerrado por
- ▶ dispensa sem justa causa nos meses seguintes.

Dados

- ▶ RAIS (Relação Anual de Informações Sociais) — base pública nacional
- ▶ de todos os vínculos formais. Anos 2019–2023, ~280 milhões de vínculos.

Validação honesta (out-of-time)

- ▶ Treina em ≤ 2022 e testa em 2023, ano nunca visto — mede a capacidade
- ▶ real de prever o futuro, não de decorar o passado.

Em números

Vínculos no teste (2023)	82,96 mi
Taxa real de dispensa	13,3%
Features do modelo	22
AUC (holdout)	0,741
Erro de calibração	< 1 p.p.
Categorias de risco	23

Preparação: features e harmonização de códigos

22 features por vínculo (todas disponíveis na RAIS)

- ▶ Ocupação (CBO) e setor (CNAE) — em níveis hierárquicos (6→1 dígito)
- ▶ Tempo de vínculo, idade, tipo de contrato, faixa de remuneração,
- ▶ tamanho e natureza da empresa, jornada, afastamentos, UF.


Harmonização de códigos entre anos (pré-processamento)

- ▶ Alguns códigos mudaram de formato entre 2022 e 2023; sem
- ▶ padronizar, o modelo veria categorias 'novas' (desconhecidas)
- ▶ no teste de 2023. A normalização garante consistência.

campo	≤ 2022	em 2023	→ normalizado
faixa salarial	02	2	2
afastamento	99	999	99
CBO (militar)	010105	10105	010105

Ex.: a categoria majoritária de afastamento ('99', ~84% dos vínculos) virava '999' em 2023 — vista como desconhecida sem o ajuste.

Como o ensemble base foi treinado



Por que cross-temporal?

- ▶ Cada modelo aprende de um par de anos
- ▶ e valida no outro; a média reduz variância.


Algoritmo

- ▶ CatBoost (gradient boosting) em GPU
- ▶ Perda e early-stopping em LogLoss
- ▶ Trata categóricas nativamente


Resultado (holdout 2023)

- ▶ AUC 0,741 · LogLoss 0,348

Desempenho: discrimina bem e é bem calibrado



Calibração: risco previsto $\approx$ observado em todos os decis (erro < 1 p.p.).
Risco de Desligamento · RAIS 2019-2023 · holdout 2023



Importância: tempo de vínculo, tipo de contrato e faixa salarial dominam (~45%).

Categorização do risco

Do score contínuo a faixas interpretáveis — maximizando o ganho de informação

Cortes que maximizam o ganho de informação

Ideia


- ▶ Fatiar a probabilidade prevista em faixas que separem ao máximo quem é desligado de quem não é (ganho de informação sobre o alvo).

Como

- ▶ Para cada nº de categorias K , a divisão ótima é achada por
- ▶ programação dinâmica (maximiza a informação mútua $I(\text{faixa}; \text{alvo})$).


Critério de parada

- ▶ Aumenta-se K enquanto o risco médio das faixas continua
- ▶ estritamente crescente. Quando a ordem quebra, para.



As 23 categorias de risco (ponto ótimo)

cat	faixa de prob.	n (mi)	taxa real	prob. méd.	lift
1	0.0-0.5%	5.5	0.6%	0.2%	0.05×
2	0.5-0.7%	1.0	1.4%	0.6%	0.11×
3	0.7-3.8%	7.0	2.9%	2.3%	0.22×
4	3.8-5.0%	3.7	4.1%	4.4%	0.31×
5	5.0-6.3%	4.3	5.4%	5.7%	0.40×
6	6.3-7.7%	5.1	6.6%	7.0%	0.50×
7	7.7-9.5%	6.8	8.1%	8.6%	0.61×
8	9.5-11.1%	6.1	9.5%	10.3%	0.72×
9	11.1-12.6%	5.5	11.0%	11.9%	0.83×
10	12.6-14.4%	6.1	12.7%	13.5%	0.95×
11	14.4-16.1%	5.2	14.5%	15.2%	1.09×
12	16.1-17.8%	4.6	16.3%	16.9%	1.23×
13	17.8-19.5%	4.0	18.3%	18.6%	1.38×
14	19.5-21.3%	3.4	20.4%	20.4%	1.53×
15	21.3-24.0%	3.7	22.9%	22.6%	1.72×
16	24.0-27.6%	3.2	26.0%	25.6%	1.96×
17	27.6-31.0%	1.8	29.1%	29.2%	2.19×
18	31.0-37.6%	2.2	31.9%	34.0%	2.40×
19	37.6-43.7%	1.2	35.4%	40.4%	2.66×
20	43.7-52.5%	1.0	39.9%	47.6%	3.00×
21	52.5-67.2%	0.9	46.1%	59.1%	3.47×
22	67.2-73.2%	0.2	57.1%	70.1%	4.30×
23	73.2-97.3%	0.5	66.7%	80.8%	5.02×



Risco de 0,6% (cat 1) a 66,7% (cat 23) — lift de até 5,0×

Personas das categorias

Quem é cada grupo de risco — segundo as variáveis da RAIS

Como cada categoria foi perfilada

Duas medidas por característica

- ▶ Composição interna — do que a categoria é feita (% de cada valor).
- ▶ Distintividade (lift) — $\text{share na categoria} \div \text{share na base}$;
- ▶ o que é desproporcionalmente comum ali (piso de 5%).



Tradução

- ▶ Códigos de CBO/CNAE/tipo de vínculo traduzidos pelo dicionário da RAIS.

Leitura

- ▶ Os indicadores são lidos ao longo das 23 categorias ordenadas
- ▶ por risco — como o perfil muda do menor para o maior risco.

O que muda à medida que o risco sobe (categorias 1 → 23)



Cada painel mostra UMA variável nas 23 categorias (eixo x). As cores do 1º painel = os 5 grupos de risco.


Risco ↑ ⇒ setor público some, tempo de casa encurta e empresa diminui: do servidor estável à construção em micro construtora.

O servidor público concursado

Categorias 1-2 · risco 0.6%-1.4% · 6.5 mi de vínculos (8% da base)

- ▶ Servidores estatutários da administração pública e educação; militares fortemente sobre-representados (lift 10×).
- ▶ Meia-idade (~46 anos), longuíssimo tempo de casa (~15 anos), nível superior, grandes órgãos.
- ▶ Estabilidade legal do serviço público → risco quase nulo (0,6–1,4%).

Perfil do grupo (médias ponderadas)



0.8%

Risco médio do grupo

46 anos

Idade média

15.7 anos

Tempo de vínculo

6%


Ensino fundamental

CLT consolidado na indústria e na saúde

Categorias 3-6 · risco 3.0%-6.6% · 20.2 mi de vínculos (24% da base)

- ▶ CLT por prazo indeterminado em indústria de alimentos e atividades de saúde; empresas de porte médio/grande.
- ▶ 5-6 anos de casa, ensino médio/superior, ~37 anos.
- ▶ Vínculo estável e maduro fora do setor público (risco 3-6,6%).

Perfil do grupo (médias ponderadas)



4.6%

Risco médio do grupo

37 anos

Idade média

6.2 anos

Tempo de vínculo

8%


Ensino fundamental

CLT do comércio e dos serviços de apoio

Categorias 7-11 · risco 8.1%-14.5% · 29.6 mi de vínculos (36% da base)

- ▶ Comércio varejista/atacadista e serviços terceirizados (limpeza, escritório, apoio a empresas).
- ▶ Empresas pequenas, muitas optantes do Simples; 2-4 anos de casa, trabalhadores mais jovens.
- ▶ Maior rotatividade típica do comércio e serviços (risco 8-14,5%).

Perfil do grupo (médias ponderadas)



11.0%

Risco médio do grupo

36 anos

Idade média

2.8 anos

Tempo de vínculo

7%


Ensino fundamental

Alimentação, varejo e o início da construção

Categorias 12-17 · risco 16.4%-29.1% · 20.7 mi de vínculos (25% da base)

- ▶ Bares, restaurantes e varejo; a partir daqui entram a produção industrial e a construção civil.
- ▶ Vínculos curtíssimos (~1,5-2 anos), micro/pequenas empresas, escolaridade começando a cair.
- ▶ Setores de alta rotatividade estrutural (risco 16-29%).

Perfil do grupo (médias ponderadas)



21.2%

Risco médio do grupo

36 anos

Idade média

1.7 anos

Tempo de vínculo

8%


Ensino fundamental

Operário da construção civil em micro construtora

Categorias 18-23 · risco 31.9%-66.7% · 6.0 mi de vínculos (7% da base)

- ▶ Construção de edifícios e obras de infraestrutura — fortíssima sobre-representação (CNAE 41/42, lift até 7,6×).
- ▶ Micro/pequenas construtoras, ensino fundamental, remuneração baixa; majoritariamente CLT 'indeterminado'.
- ▶ O modelo capta a rotatividade ESTRUTURAL do setor: na cat 23, 2 em cada 3 são desligados no ano (66,7%).

Perfil do grupo (médias ponderadas)



40.0%

Risco médio do grupo

37 anos

Idade média

1.9 anos

Tempo de vínculo

12%

Ensino fundamental

Síntese

- Ensemble CatBoost cross-temporal prevê dispensa sem justa causa com AUC 0,741 e boa calibração.
- A harmonização de códigos entre anos garante a consistência do modelo no teste de 2023.
- O score foi fatiado em 23 categorias ótimas (máximo ganho de informação mantendo a ordenação).
- As personas vão do servidor público estável (risco ~1%) ao operário da construção em micro construtora (risco ~67%) — o modelo capta rotatividade estrutural, não só contrato temporário.

Apêndice — Personas para consignado privado

Excluindo o setor público (servidores não são o público-alvo do consignado privado)

Por que remover o setor público

Uso pretendido: consignado PRIVADO

- ▶ O servidor público tem canal próprio de consignado — não é o público-alvo aqui.
- ▶ Removendo o setor público saem 14.2 mi de vínculos (17% da base);
- ▶ restam 68.8 mi de trabalhadores do setor privado.

O que muda nas personas

- ▶ O setor público dominava as categorias de MENOR risco (estabilidade legal).
- ▶ Sem ele, o piso de risco passa a ser o trabalhador privado mais estável —
- ▶ veteranos de banco/grandes empresas — não mais o servidor concursado.
- ▶ Risco médio e alto (comércio, serviços, construção) quase não mudam.

Grupo Risco Mínimo (cat 1-2)

Base completa

6.5 mi

≈87% servidores públicos

Só setor privado

0.8 mi


bancos/utilities · 14 anos de casa

Veteranos de banco e de grandes empresas estáveis

Categorias 1-2 · risco 0.1%-0.2% · 0.8 mi de vínculos (1% do privado)

- ▶ Setor financeiro (bancos — CNAE 64, lift 11x) e serviços essenciais/utilities (saneamento, correio); grandes empregadores privados.
- ▶ Longuíssimo tempo de casa (11-14 anos), mais velhos (42-50); muitos em afastamento de longa duração (estabilidade de fato).
- ▶ Sem o setor público, este é o PISO de risco do crédito privado (0,07-0,18%).

Perfil do grupo (médias ponderadas)



0.1%

Risco médio do grupo

48 anos

Idade média

13.6 anos

Tempo de vínculo

18%


Ensino fundamental

CLT qualificado e consolidado (financeiro, saúde, indústria)

Categorias 3-6 • risco 2.0%-6.2% • 15.5 mi de vínculos (23% do privado)

- ▶ CLT por prazo indeterminado em setor financeiro, saúde, indústria de alimentos e educação privada; 5-6 anos de casa, ensino médio/superior.
- ▶ No início do grupo (cat 3) entram temporários de agência e profissionais qualificados — é aqui que cai o bancário típico.
- ▶ Risco de 2-6%, bem abaixo da média.

Perfil do grupo (médias ponderadas)



4.4%

Risco médio do grupo

36 anos

Idade média

5.7 anos

Tempo de vínculo

8%


Ensino fundamental

CLT do comércio e dos serviços de apoio

Categorias 7-11 · risco 7.7%-14.4% · 27.6 mi de vínculos (40% do privado)

- ▶ Comércio (varejo/atacado) e serviços terceirizados (limpeza, apoio a empresas); empresas pequenas, muitas no Simples; 2-4 anos de casa.
- ▶ Trabalhadores mais jovens; rotatividade típica do comércio e dos serviços (8-14%).

Perfil do grupo (médias ponderadas)



10.8%

Risco médio do grupo

36 anos

Idade média

2.9 anos

Tempo de vínculo

7%


Ensino fundamental

Alimentação, varejo e início da construção

Categorias 12-17 · risco 16.4%-30.0% · 19.4 mi de vínculos (28% do privado)

- Bares/restaurantes e varejo; a partir daqui entram a produção industrial e a construção civil; vínculos curtos (~1,5-2 anos).
- Micro/pequenas empresas; escolaridade começando a cair (risco 16-30%).

Perfil do grupo (médias ponderadas)



21.5%

Risco médio do grupo

36 anos

Idade média

1.7 anos

Tempo de vínculo


8%

Ensino fundamental

Operário da construção civil em micro construtora

Categorias 18-23 · risco 32.8%-67.0% · 5.4 mi de vínculos (8% do privado)

- Construção de edifícios e obras de infraestrutura (CNAE 41/42, lift 4-6x); micro/pequenas construtoras; ensino fundamental.
- Quase 100% CLT 'indeterminado' — rotatividade ESTRUTURAL do setor: até 67% desligados no ano (cat 23).



41.5%

Risco médio do grupo

37 anos

Idade média

1.9 anos

Tempo de vínculo

13%

Ensino fundamental

Apêndice — Quando ocorre o desligamento

Curvas de sobrevivência e tempo até a dispensa, por categoria de risco

Curvas de sobrevivência por categoria (Kaplan-Meier)

A ideia


- ▶ O modelo prevê QUEM/SE é desligado; a sobrevivência mede QUANDO.
- ▶ $S(t)$ = probabilidade de continuar empregado após t meses.

Dos microdados (RAIS)

- ▶ Evento = dispensa s/ justa causa; tempo = mês do desligamento
- ▶ Censura: quem fica ativo (ou sai por outro motivo) não é 'evento'.

Kaplan-Meier

- ▶ $S(t) = \prod (n_m - d_m) / n_m$ — usa a censura sem viés, mês a mês.
- ▶ $RMST(12)$ = área sob $S(t)$ = meses esperados de emprego no ano.



Estendendo as curvas além de 12 meses (Weibull)

O problema


- ▶ 12 meses de dado não enxergam além de 12m (a curva ainda está alta).

Solução: forma paramétrica de Weibull


- ▶ $S(t) = \exp(-(t/\lambda)^p)$; hazard $\propto t^{(p-1)}$ ($p > 1$ sobe, $p < 1$ cai).
- ▶ Ajuste por regressão pura: $\ln(-\ln S) = p \cdot \ln t + \ln \alpha$ (OLS, 12 pts).
- ▶ R^2 médio $\approx 0,99$ — extrapola a curva até 36 meses (tracejado).

Ressalva

- ▶ Ignora a sazonalidade de dezembro; projeção >12m é suposição.



Q1, mediana, média e Q3 por categoria (meses)



cat	Q1	med	méd	Q3
1	481	1111	1543	2148
2	197	430	569	794
3	78	156	193	270
4	44	80	94	130
5	35	64	75	103
6	30	55	63	88
7	26	46	54	74
8	22	41	47	65
9	20	36	42	58
10	18	33	38	53
11	16	30	35	48
12	15	28	34	47
13	14	27	33	45
14	13	25	33	45
15	12	24	33	45
16	10	23	33	45
17	9	22	33	45
18	8	22	33	45
19	6	21	33	45
20	4	16	33	45
21	3	10	20	26
22	3	7	10	13
23	3	6	7	10